

Análisis completo del TSPTW: métodos exactos, metaheurísticas y LKH-3

Rafael Rodríguez
Departamento de Ingeniería
Universidad Andrés Bello
Santiago, Chile

Josefa Iturra
Departamento de Ingeniería
Universidad Andrés Bello
Santiago, Chile

Abstract—El Traveling Salesman Problem with Time Windows (TSPTW) es una extensión al problema del viajante incorporando intervalos de tiempo en los que cada cliente puede ser visitado. Este trabajo presenta una revisión de dicho problema, incluyendo su formulación, contexto, complejidad computacional y principales aplicaciones en ámbitos de logística y servicio. Se analiza el estado de arte de métodos exactos, heurísticos, metaheurísticos y enfoques basados en aprendizaje automático, con especial énfasis en el solver LKH-3. Se concluye que, pese al avance en investigaciones, LKH-3 permanece como una herramienta de referencia para instancias de gran tamaño.

Abstract— The Traveling Salesman Problem with Time Windows (TSPTW) extends the classical traveling salesman problem by imposing time intervals within which each customer must be visited. This paper provides a review of the problem, covering its formulation, context, computational complexity, and key applications in logistics and service settings. We survey exact, heuristic, and metaheuristic methods, along with machine learning-based approaches, with particular emphasis on the LKH-3 solver. We conclude that, despite ongoing research progress, LKH-3 remains a benchmark tool for large-scale instances.

Palabras clave—LKH-3, Solver, heurística, metaheurística, TSPTW, optimización, nodos, rutas, costos, restricciones.

I. INTRODUCCIÓN Y MOTIVACIONES

En distintos contextos reales, un vehículo o profesional debe visitar múltiples ubicaciones respetando horarios previamente definidos. No solo basta con recorrer la menor distancia posible: cada destino solo puede atenderse dentro de un intervalo de tiempo determinado. Cuando llegamos antes, debemos esperar, cuando llegamos después, la ruta deja de ser válida. Este tipo de situaciones se modelan naturalmente como problemas de ruteo con restricciones temporales.

Uno de los problemas clásicos de esta familia es el TSPTW (Traveling Salesman Problem with Time Windows), una variante del conocido Traveling Salesman Problem (TSP). En el TSPTW, dado un conjunto de nodos, debemos determinar una secuencia de visita que permita recorrerlos de manera eficiente, respetando sus respectivas ventanas de tiempo. El objetivo es minimizar el costo total del recorrido, visitando cada nodo una sola vez y cumpliendo las ventanas asociadas a cada uno.

La principal motivación para indagar en este tipo de problema es su alcance real. Su naturaleza industrial hace que sus soluciones impacten directamente en servicios que usamos a diario, como la distribución de productos, el delivery o las visitas domiciliarias de salud, donde incumplir un horario puede invalidar toda la ruta. Por eso, su investigación y documentación resulta relevante para entender cómo se planifican recorridos eficientes en la práctica.

Al igual que el TSP, el TSPTW es un problema NP-duro. En instancias grandes, encontrar la solución óptima se vuelve cada vez más difícil, por lo que muchas veces se recurre a heurísticas y metaheurísticas que entregan soluciones de buena calidad en tiempos razonables.

El presente trabajo revisa el TSPTW desde una perspectiva teórico-bibliográfica. Se presenta su definición formal y formulación matemática, se analiza su complejidad computacional y se describen aplicaciones en contextos reales. También se revisa el estado del arte de los métodos de resolución, desde enfoques exactos hasta metaheurísticas y aprendizaje automático, con especial énfasis en el solver LKH-3, asignado en el marco del curso como herramienta heurística de referencia para esta variante. La Sección II aborda la definición y formulación; la III, complejidad y aplicaciones, la IV, estado del arte, la V, LKH-3, y la VI, brechas y trabajo futuro.

II. DEFINICIÓN Y FORMULACIÓN

A. Definición Formal del Problema

El TSPTW se define sobre un conjunto de nodos $V = \{0, 1, \dots, n\}$, donde el nodo 0 representa el depósito o punto de partida y los restantes corresponden a clientes o ubicaciones que deben visitarse. A diferencia del TSP clásico, aquí cada nodo $i \in V$ tiene asociada una ventana de tiempo $[e_i, l_i]$ con e_i como instante mínimo de llegada y l_i como instante máximo. Además, se considera una matriz de costos c_{ij} , que representa el costo de desplazarse del nodo i al nodo j , y un tiempo de servicio s_i en cada nodo. Los datos de entrada al problema son, entonces, el conjunto de nodos, la matriz de costos, las ventanas de tiempo y los tiempos de servicio. El tiempo de llegada a cada nodo no corresponde a un dato, sino un valor que se determina a partir de una ruta seleccionada. El objetivo es encontrar un recorrido que visite todos los nodos exactamente una vez, minimizando el costo total del recorrido y cumpliendo que la llegada a cada nodo ocurra dentro de su ventana: si se llega antes a e_i , se espera hasta su instante, en caso de llegar después de l_i , la solución se considera infactible. Cabe señalar que el TSPTW no posee vehículos con restricciones de capacidad, a diferencia de otros problemas como VRPTW, donde múltiples vehículos intervienen y existen limitaciones adicionales.

B. Formulación Matemática

A continuación se presenta una formulación MILP estándar para el TSPTW. Se utilizan variables binarias para representar los arcos del recorrido y variables continuas para modelar los tiempos de llegada a cada nodo. La formulación como objetivo busca minimizar el costo total del recorrido, garantizando que, cada cliente sea visitado una sola vez bajo las ventanas de tiempo correspondientes.

B.1 Conjuntos y parámetros

B.1.1 Conjuntos

- $V = \{0, 1, \dots, n\}$: conjunto de nodos, donde 0 es el depósito y $1, \dots, n$ son los nodos a visitar.
- $A = \{(i, j) : i, j \in V, i \neq j\}$: conjunto de arcos posibles entre nodos.

B.1.2 Parámetros

- c_{ij} : costo de desplazamiento entre el nodo i al nodo j , con $(i, j) \in A$.
- e_i : ventana de tiempo inicial.
- l_i : ventana de tiempo final.
- s_i : tiempo de servicio en nodo i .
- M : constante Big-M para las restricciones temporales.

B.2 Variables de decisión

- $x_{ij} \in \{0, 1\}$: toma valor 1 si viaja del nodo i al nodo j , y 0 en caso contrario.
- $t_i \geq 0$: tiempo de llegada al nodo i

La variable x_{ij} define la estructura del recorrido, mientras que t_i verifica que las ventanas de tiempo se cumplan y que los tiempos sean consistentes entre nodos consecutivos.

B.3 Funciones y restricciones

B.3.1 Función Objetivo

$$\min \sum_{(i,j) \in A} c_{ij} x_{ij} \quad (1)$$

B.3.2 Restricciones

$$\sum_{j \in V} x_{ij} = 1 \quad \forall i \in V \quad (2)$$

$$\sum_{i \in V} x_{ij} = 1 \quad \forall j \in V \quad (3)$$

$$e_i \leq t_i \leq l_i \quad \forall i \in V \quad (4)$$

$$t_j \geq t_i + s_i + c_{ij} - M(1 - x_{ij}) \quad \forall (i, j) \in A \quad (5)$$

$$u_i - u_j + (n + 1)x_{ij} \leq n \quad \forall i, j \in V \setminus \{0\}, i \neq j$$

$$e_i \leq u_i \leq l_i \quad \forall i \in V \setminus \{0\}$$

$$u_0 = e_0 \quad (6)$$

En conjunto a la función objetivo (1) que busca minimizar el costo del conjunto de nodos visitado, las restricciones (2) y (3) definen un tour hamiltoniano sobre los nodos, las restricciones (4) y (5) garantizan la factibilidad temporal, y la restricción (6) evita soluciones con subtours. Esta formulación es una representación compacta del TSPTW en forma MILP, métodos exactos como los de Dumas et al [1] la utilizan o variantes equivalentes, mientras que en instancias grandes se recurre a heurísticas como LKH-3 [11].

III. COMPLEJIDAD COMPUTACIONAL Y APLICACIONES

El TSP clásico, es decir, sin ventanas de tiempo, ya es un problema NP-duro: encontrar la solución óptima se vuelve cada vez más complejo a medida que aumenta el tamaño de la instancia. El TSPTW es al menos tan difícil como el TSP, pues

este último puede verse como un caso particular donde las ventanas son lo suficientemente amplias como para no restringir la ruta. En consecuencia, no se conoce un algoritmo polinomial que resuelva el TSPTW de forma óptima en el peor caso. No obstante, verificar si una ruta dada es factible resulta relativamente sencillo: basta recorrer la secuencia de nodos, calcular los tiempos de llegada y comprobar que cada ventana se cumple, lo cual puede hacerse en tiempo $O(n)$, donde n es el número de clientes.

En el TSPTW la dificultad aumenta porque no solo hay que minimizar el costo del recorrido, sino también garantizar su factibilidad temporal. Métodos exactos como la programación dinámica propuesta por Dumas et al. [1] o los enfoques Branch-and-Cut de Ascheuer et al. [2] permiten obtener soluciones óptimas, pero su aplicación práctica se limita a instancias de tamaño moderado, típicamente decenas de nodos ya que la incorporación de ventanas de tiempo incrementa significativamente el espacio de búsqueda. Por esta razón, en instancias de gran tamaño la resolución suele apoyarse en heurísticas y metaheurísticas, las cuales entregan soluciones de alta calidad en tiempos razonables. Dentro de este contexto, solvers como LKH-3 [11] han mostrado resultados competitivos en problemas de ruteo con restricciones.

El TSPTW posee una amplia variedad de aplicaciones en problemas reales donde las visitas deben realizarse dentro de intervalos de tiempo específicos. En logística de distribución, un vehículo debe abastecer múltiples sucursales respetando los horarios de recepción de cada destino, minimizando el costo de transporte sin incumplir las ventanas [3]. En delivery, las plataformas de reparto deben planificar rutas que permitan entregar pedidos dentro de los plazos comprometidos con los clientes. En salud, profesionales como médicos o enfermeros coordinan visitas domiciliarias considerando horarios previamente acordados con los pacientes. Finalmente, en transporte de pasajeros o servicios de traslado, los recorridos deben cumplir horarios definidos para cada parada, donde las restricciones temporales son fundamentales para mantener la calidad del servicio. En conjunto, estos escenarios explican por qué el TSPTW sigue siendo un problema relevante tanto en la academia como en la industria [8]

IV. ESTADO DEL ARTE

Gran parte de la literatura sobre ruteo con ventanas de tiempo se ha desarrollado en torno al VRPTW, donde intervienen múltiples vehículos y, en muchos casos, restricciones de capacidad. El TSPTW corresponde al caso particular en el que existe un único vehículo y no se considera capacidad, lo que lo hace estructuralmente más simple, aunque sigue siendo NP-duro. Aun así, muchos de los métodos diseñados para el VRPTW han servido de base para abordar el TSPTW, especialmente en heurísticas constructivas y metaheurísticas. Por esta razón, la revisión que sigue considera ambas líneas de trabajo cuando aportan al entendimiento del problema tratado.

A. Métodos Exactos

Gracias a la complejidad computacional del TSPTW, históricamente los primeros trabajos se centraron en métodos exactos capaces de garantizar soluciones óptimas. Dumas et al. [1] propusieron un algoritmo óptimo basado en programación dinámica que constituye una referencia clásica para el TSPTW, permitiendo resolver instancias pequeñas y medianas con certeza de optimalidad. Además de la programación dinámica, otros

enfoques exactos como branch-and-bound exploran el espacio de soluciones mediante ramificación y poda, descartando rutas parciales infactibles o de costo elevado antes de completar el recorrido. Posteriormente, enfoques basados en Branch-and-Cut como el desarrollado por Ascheuer et al.[2] para el caso asimétrico con ventanas de tiempo extendieron la capacidad de los métodos exactos mediante relajaciones lineales y cortes de separación.

Estos métodos comparten una limitación práctica: su costo computacional crece muy rápido con el tamaño de la instancia. Por ello, su aplicación se restringe, en general, a problemas con decenas de nodos. En instancias más grandes, obtener la solución óptima deja de ser viable en tiempos razonables, lo que motivó el desarrollo de heurísticas y metaheurísticas que sacrifican la garantía de optimalidad a cambio de velocidad y escalabilidad.

B. Heurísticas y Búsqueda Local.

Más adelante surgieron heurísticas constructivas orientadas a generar soluciones factibles en tiempos reducidos. Una referencia central es el trabajo de Solomon [3], quien desarrolló procedimientos de inserción para problemas de ruteo con ventanas de tiempo, sentando las bases para métodos posteriores. Estas heurísticas no buscan la optimalidad, pero entregan rutas viables que pueden servir como punto de partida para fases de mejora.

Sobre esa base, la búsqueda local mediante operadores como 2-opt, Or-opt y variantes k-opt permitió refinar rutas ya construidas intercambiando arcos o reinsertando segmentos. Helsgaun [16],[10] profundizó en implementaciones eficientes de la heurística de Lin–Kernighan, sentando las bases del solver LKH, que más tarde evolucionaría hacia LKH-3. Bräysy y Gendreau [8] revisaron en detalle los métodos constructivos y de búsqueda local para problemas con ventanas de tiempo, consolidando el conocimiento acumulado hasta entonces.

C. Metaheurísticas

Con el objetivo de mejorar la calidad de las soluciones sin sacrificar demasiado costo computacional, se desarrollaron metaheurísticas que exploran el espacio de soluciones de forma más amplia que una heurística constructiva aislada. Entre las más influyentes se encuentran la búsqueda Tabú propuesta por Gendreau et al. [4], los algoritmos genéticos estudiados por Potvin y Bengio [5], los métodos basados en colonias de hormigas de Gambardella et al. [6], los algoritmos evolutivos analizados por Bräysy et al. [7] y el Simulated Annealing (recocido simulado), que permite escapar de óptimos locales mediante criterios probabilísticos de aceptación de movimientos. Bräysy y Gendreau [9] presentaron además una revisión sistemática de las principales metaheurísticas aplicadas a problemas con ventanas de tiempo incluyendo las mencionadas convirtiéndose en una referencia fundamental para comprender su evolución y su capacidad de explorar soluciones diversas en instancias de gran tamaño.

Es importante aclarar que estas metaheurísticas no garantizan la solución óptima. Su aporte está en encontrar soluciones de alta calidad en instancias de gran tamaño, donde los métodos exactos dejan de ser prácticos. En la práctica, muchas

implementaciones combinan una fase constructiva con una fase de mejora local o metaheurística, equilibrando factibilidad, calidad y tiempo de cómputo.

D. LKH-3 y Heurísticas de Alto Rendimiento

Dentro de este contexto surge LKH-3 [11], un solver que extiende la heurística Lin–Kernighan–Helsgaun para abordar variantes del TSP y problemas de ruteo con restricciones adicionales. A diferencia de muchas metaheurísticas clásicas, LKH-3 se apoya en movimientos de búsqueda local avanzada, conjuntos de candidatos y mecanismos de penalización que permiten tratar ventanas de tiempo y otras restricciones dentro de un mismo marco. En diversas instancias de referencia ha reportado resultados competitivos frente a métodos exactos en tamaño moderado y frente a metaheurísticas en instancias grandes.

LKH-3 no reemplaza por completo a las metaheurísticas anteriores, pero ocupa un lugar relevante en el panorama actual: combina la eficiencia de la búsqueda local especializada con la flexibilidad para múltiples variantes de ruteo. El rol específico de LKH-3 en el TSPTW se analiza con mayor detalle en la Sección V

E. Aprendizaje Automático

En los últimos años han aparecido enfoques basados en aprendizaje automático que buscan aprender estrategias de construcción o mejora de rutas a partir de datos. Kool et al. [12] propusieron un modelo basado en atención (Attention) capaz de abordar problemas de ruteo de forma autorregresiva. Xin et al. [13] presentaron NeuroLKH, que combina aprendizaje profundo con la heurística Lin–Kernighan–Helsgaun, intentando aprovechar lo mejor de ambos enfoques. Joshi et al. [14], por su parte, analizaron críticamente la capacidad de generalización de modelos de aprendizaje aplicados al TSP, mostrando que aún existen limitaciones importantes al enfrentar instancias distintas a las usadas en entrenamiento, Cappart et al. [15] revisaron además el uso de Graph Neural Networks en problemas de optimización combinatoria, consolidando una perspectiva más amplia sobre las oportunidades y limitaciones del aprendizaje automático en este ámbito.

Estos métodos representan una línea prometedora, pero todavía enfrentan desafíos relacionados con la generalización, la robustez y la escalabilidad. Por ello, en muchos contextos aplicados LKH-3 [11] y las metaheurísticas clásicas siguen siendo referencias sólidas, mientras que el aprendizaje automático se consolida principalmente en nichos experimentales o híbridos.

TABLA I — COMPARACIÓN DE ENFOQUES DE RESOLUCIÓN PARA EL TSPTW

Enfoque	Tipo de solución	Escala	Referencia
PD	Óptima	N ~ 40	[1]
B&C	Óptima	N moderado	[2]
HEU de inserción	Factible	N grande	[3]
K-opt/LKH	Heurística	N grande	[10], [16]
Tabú/ACO/EA/ GA	Heurística	N grande	[4]-[7]
LKH-3	Heurística	N grande	[11]
GNN/NEUROLKH	Aprendizaje	Variable	[12]-[15]

F. Síntesis Comparativa

En conjunto, el estado del arte del TSPTW refleja una evolución clara: de métodos exactos capaces de certificar optimalidad en instancias pequeñas, hacia heurísticas y metaheurísticas que priorizan escalabilidad, hasta solvers especializados como LKH-3 y, más recientemente, enfoques basados en aprendizaje automático. La Tabla I resume esta transición en términos de garantía de solución, escala típica de instancias y referencias representativas.

En síntesis, la literatura ha pasado de buscar soluciones exactas en contextos acotados, al desarrollo de heurísticas y metaheurísticas que hicieron posible abordar instancias reales de mayor tamaño, hasta la aparición de LKH-3 como herramienta de alto rendimiento y, en la actualidad, la exploración de algoritmos de aprendizaje que aún deben demostrar su madurez frente a métodos consolidados

V. ROL ESPECÍFICO DE LKH-3 EN EL TSPTW

Como solver, LKH-3 destaca por sus métodos de búsqueda local avanzada heredados de la heurística Lin-Kernighan-Helsgaun y por el uso de funciones de penalización para el manejo de restricciones [11]. A diferencia de muchas metaheurísticas clásicas, no parte de cero en cada instancia: se apoya en movimientos k-opt, conjuntos de candidatos y mecanismos de backtracking que permiten explorar el espacio de rutas de forma eficiente. Gracias a estas características, LKH-3 puede abordar distintas variantes del TSP y problemas de ruteo incluido el TSPTW mediante transformaciones que adaptan las restricciones del problema al núcleo del algoritmo.

En el caso particular del TSPTW, las ventanas de tiempo se incorporan como restricciones dentro del proceso de búsqueda. Para ello, el algoritmo utiliza funciones de penalización que detectan y castigan las violaciones

temporales: las rutas que incumplen alguna ventana reciben una penalización adicional, mientras que aquellas factibles y de menor costo son favorecidas durante la exploración. De esta manera, la búsqueda se orienta progresivamente hacia soluciones temporalmente factibles y de alta calidad, sin garantizar optimalidad pero logrando buenos resultados incluso en instancias de gran tamaño. Helsgaun [11] reporta que LKH-3 obtiene resultados competitivos en una amplia variedad de instancias de referencia para problemas de ruteo con restricciones, posicionándose como alternativa práctica frente a métodos exactos en instancias medianas y frente a metaheurísticas genéricas en instancias grandes.

Cabe señalar que el desempeño de LKH-3 depende de la calidad de la solución inicial y de los parámetros de penalización, por lo que no reemplaza el análisis de factibilidad propio de formulaciones exactas como la de Dumas et al. [1]. No obstante, en este contexto donde LKH-3 se asigna como herramienta heurística de referencia resulta especialmente relevante por su capacidad de tratar ventanas de tiempo dentro de un mismo marco usado para múltiples variantes de ruteo, consolidando décadas de avance en búsqueda local especializada [16], [10], [11].

VI. PROYECCIÓN Y TRABAJO A FUTURO.

Si bien el TSPTW cuenta con avances importantes y una amplia documentación, aún existen brechas de investigación asociadas. Sabemos que solvers como LKH-3 y otras metaheurísticas producen soluciones muy buenas, sin embargo, a medida que el espacio de búsqueda crece, encontrar rutas de alta calidad en tiempos razonables sigue siendo un desafío. Esto es especialmente relevante en el TSPTW, donde la factibilidad temporal reduce el conjunto de rutas admisibles y puede hacer más difícil, incluso para heurísticas consolidadas, identificar recorridos que cumplan todas las ventanas sin sacrificar demasiado costo.

Por otra parte, muchos problemas reales no consideran solo ventanas de tiempo. También incorporan capacidades de vehículos, múltiples depósitos, recogidas y entregas, así como condiciones dinámicas como tráfico, nuevos pedidos, cancelaciones o retrasos. Esto exige algoritmos capaces de re-optimizar rutas en tiempo real y de integrar combinaciones más amplias de restricciones, lo que va más allá del TSPTW clásico pero marca una línea natural de extensión del problema estudiado. En este sentido, los métodos exactos siguen siendo valiosos para instancias pequeñas y para validar soluciones, mientras que las heurísticas y metaheurísticas incluido LKH-3 permanecen como la herramienta principal en contextos operacionales de mayor escala Helsgaun [11], Bräysy y Gendreau [9].

En consecuencia, el auge de la inteligencia artificial ha impulsado enfoques basados en Reinforcement Learning, Graph Neural Networks y propuestas híbridas como NeuroLKH [12] – [14] que buscan combinar aprendizaje automático con heurísticas clásicas. Estos métodos resultan prometedores, pero aún enfrentan desafíos de escalabilidad, robustez y generalización frente a instancias no vistas en entrenamiento. Por ello, el trabajo futuro apunta tanto al perfeccionamiento de solvers especializados como LKH-3, como al desarrollo de enfoques híbridos que integren aprendizaje y optimización combinatoria de forma más confiable en escenarios reales.

VII. USO DE IA

En esta sección se declara el uso de modelos LLM como ChatGPT exclusivamente para la elaboración de pipelines de acción, centralización de referencias, verificación de ortografía, coherencia y cohesión con los temas tratados en el paper. Cada una de las referencias propuestas fue verificada y leída con detenimiento por los integrantes.

VIII. REFERENCIAS

- [1] Y. Dumas, J. Desrosiers, E. Gelinas, and M. M. Solomon, "An optimal algorithm for the traveling salesman problem with time windows," *Oper. Res.*, vol. 43, no. 2, pp. 267–283, Mar.–Apr. 1995.
- [2] N. Ascheuer, M. Fischetti, and M. Grötschel, "Solving the asymmetric traveling salesman problem with time windows by branch-and-cut," *Math. Program.*, vol. 90, no. 3, pp. 475–506, 2001.
- [3] M. M. Solomon, "Algorithms for the vehicle routing and scheduling problems with time window constraints," *Oper. Res.*, vol. 35, no. 2, pp. 254–265, 1987.
- [4] M. Gendreau, A. Hertz, and G. Laporte, "A tabu search heuristic for the vehicle routing problem," *Manage. Sci.*, vol. 40, no. 10, pp. 1276–1290, 1994.
- [5] J.-Y. Potvin and S. Bengio, "The vehicle routing problem with time windows part II: Genetic search," *INFORMS J. Comput.*, vol. 8, no. 2, pp. 165–172, 1996.
- [6] L. M. Gambardella, É. Taillard, and G. Agazzi, "MACS-VRPTW: A multiple ant colony system for vehicle routing problems with time windows," in *New Ideas in Optimization*, D. Corne, M. Dorigo, and F. Glover, Eds. London, U.K.: McGraw-Hill, 1999, pp. 63–76.
- [7] O. Bräysy, W. Dullaert, and M. Gendreau, "Evolutionary algorithms for the vehicle routing problem with time windows," *J. Heuristics*, vol. 10, no. 5, pp. 473–492, 2004.
- [8] O. Bräysy and M. Gendreau, "Vehicle routing problem with time windows, Part I: Route construction and local search algorithms," *Transport. Sci.*, vol. 39, no. 1, pp. 104–118, 2005.
- [9] O. Bräysy and M. Gendreau, "Vehicle routing problem with time windows, Part II: Metaheuristics," *Transport. Sci.*, vol. 39, no. 1, pp. 119–139, 2005.
- [10] K. Helsgaun, "General k-opt submoves for the Lin-Kernighan TSP heuristic," *Math. Program. Comput.*, vol. 1, no. 2–3, pp. 119–163, 2009.
- [11] K. Helsgaun, "An extension of the Lin-Kernighan-Helsgaun TSP solver for constrained traveling salesman and vehicle routing problems," Roskilde Univ., Roskilde, Denmark, Tech. Rep., 2017.
- [12] W. Kool, H. van Hoof, and M. Welling, "Attention, learn to solve routing problems!" in *Proc. Int. Conf. Learn. Represent. (ICLR)*, New Orleans, LA, USA, 2019.
- [13] L. Xin, W. Song, Z. Cao, and J. Zhang, "NeuroLKH: Combining deep learning model with Lin-Kernighan-Helsgaun heuristic for solving the traveling salesman problem," in *Proc. Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 34, 2021, pp. 7472–7483.
- [14] C. K. Joshi, Q. Cappart, L.-M. Rousseau, and T. Laurent, "Learning the travelling salesperson problem requires rethinking generalization," *Constraints*, vol. 27, no. 1–2, pp. 70–98, 2022.
- [15] Q. Cappart et al., "Combinatorial optimization and reasoning with graph neural networks," *J. Mach. Learn. Res.*, vol. 24, no. 130, pp. 1–61, 2023.
- [16] K. Helsgaun, "An effective implementation of the Lin-Kernighan traveling salesman heuristic," *Eur. J. Oper. Res.*, vol. 126, no. 1, pp. 106–130, 2000.